

【1】 Kawaguchi:summarize the next attached file.

この NBER ワーキングペーパー「**AI in Science**」(2026 年 3 月)は、アジャイ・K・アグラワル、ジョン・マクヘイル、アレクサンダー・オットルによって執筆され、人工知能 (AI) が科学的発見のプロセスと知識生産関数にどのような影響を与えるかを考察しています。

主な論点は以下の通りです。

1. 科学研究のマルチステージ・モデル

論文では、科学プロセスを「質問生成」「アイデア生成」「デザイン生成」「テスト (検証)」の 4 つの主要なステージに分解しています。

- **探索の革命:** AI の真の価値は、人間には不可能なほど巨大で複雑な「組み合わせの探索空間」を効率的にナビゲートする「予測マシン」としての能力にあります。
- **ボトルネック:** いずれかのステージでの停滞 (例: 物理的な臨床試験の遅れ) が全体の生産性を抑制する可能性があります。

2. 人間の「判断」の重要性

AI が探索を加速させる一方で、以下の領域では人間の判断が依然として不可欠であると強調されています。

- **仮説的推論 (Abductive Inference):** データが乏しい環境での「推測」や、文脈に応じた微妙なニュアンスの理解。
- **トレードオフの評価:** 倫理的な考慮や、相反する目的 (例: 新薬の有効性と安全性) の優先順位付け。

3. ドメイン (分野) による異質性

AI の影響は分野によって異なります。

- **データ豊富 (生物学・材料科学):** AlphaFold のようなツールがデザイン生成を劇的に加速させ、生産性を大幅に向上させています。
- **異常値が稀 (物理学):** 物理学的な「パラダイムシフト」を伴う洞察には、データ主導の補完よりも、人間の直感や理論的判断がより重要な役割を果たします。

4. 汎用メタ・テクノロジー (GPMT) としての AI

AI は単なる汎用技術 (GPT) ではなく、「新しい技術を発明するための技術」である GPMT と定義されています。

- **ギザギザのフロンティア (Jagged Frontier):** AI の能力は領域ごとに不均一であり、そのフロンティアを拡張するには、上流 (AI アルゴリズムの改善) と下流 (科学者のスキル習得や組織の再編成) の両方への投資が必要です。

5. 労働とスキル: タスクベースのモデル

AI が科学者の生産性に与える影響を、タスクベースのモデルで説明しています。

- **AI 専門家:** AI を使いこなす専門家が増えるほど、AI 技術の向上による生産性向上の効果が非線形に増幅されます。
- **格差と集中:** AI が特定のスキルを必要としなくなる（タスク・オープニング）か、逆に高度な専門性を必要とする（タスク・クロージング）かによって、賃金格差や研究テーマの集中度が変化します。

6. 潜在的なリスク

AI の普及には以下のようなマイナスの側面も懸念されています。

- **知識の崩壊:** AI への過度な依存により、人間が学習や理解を怠ることで、社会全体の知識ベースが損なわれるリスク（アセモグルらの理論）。
- **査読システムの崩壊:** AI による論文投稿の急増が、従来の査読プロセスを圧倒してしまう可能性。
- **多様性の低下:** AI が既存のデータに基づいた「確実な」テーマに研究を集中させ、科学的な探索の幅を狭めてしまう可能性。

この論文は、AI を自動化のツールではなく、人間の科学的な「判断」を拡張・補完するツールとして捉えることで、科学の生産性を劇的に高め、ひいては経済成長を加速させる可能性を提示しています。

【2】Kawaguchi:上の添付ファイルを段落ごとに要約できるか？

ご提示いただいた論文「AI in Science」(Source 3) の主要なセクションおよび段落ごとの構成に基づき、その内容を要約します。

「AI in Science」セクション別要約

1. 序論：AI は経済成長を加速させるか？

- **成長への影響に関する議論:** ダロン・アセモグル（控えめな成長予測）とチャド・ジョーンズ（アイデア生産の加速による大幅な成長の可能性）という、二人の経済学者の対照的な見解を比較しています。
- **開発者側の楽観論:** Anthropic、OpenAI、DeepMind の CEO たちは、AI が生物学や医学の進歩を数十年の単位で圧縮すると予測しており、ジョーンズの見解に近い立場をとっています。
- **本論文の立場:** 著者は、AI が科学の「組み合わせ探索」を効率化するというジョーンズ的な視点と、人間の判断力やワークフローのボトルネックが重要であるというアセモグル的な視点の両方を取り入れたモデルを提示しています。

2. AI と科学的生産性の多段階モデル

- **4つのステージ:** 科学プロセスを「質問生成」「アイデア生成」「デザイン生成」「テスト」の4段階に定義しています。
- **探索の革命:** AIの真の力は、膨大な組み合わせの中から有望なものを特定する「予測マシン」としての機能にあり、特にデザイン生成ステージで顕著です。
- **人間による判断の役割:** データが乏しい環境での推論、文脈の理解、倫理的なトレードオフの評価において、人間の「判断力」は依然として不可欠な補完物であるとされています。

3. 分野別の洞察（ドメイン特化型の影響）

- **材料科学・生物学:** AlphaFoldのようなツールがタンパク質構造予測を劇的に加速させるなど、データが豊富な分野では「デザイン生成」のボトルネックが解消されつつあります。
- **物理学・数学:** 物理学的なパラダイムシフトや数学的な美学を伴う問題では、データ主導の予測よりも人間の直感的判断や理論的枠組みが重要視されます。
- **医学・経済学:** 医学ではAIによる新薬候補の発見が進む一方で、臨床試験（テスト）が物理的なボトルネックとなります。経済学では因果推論のツールとしてAIが活用されますが、社会的な文脈の理解には人間が必要です。

+1

4. 汎用メタ・テクノロジー（GPMT）としてのAI

- **メタ・アイデアの具現化:** AIは単なる汎用技術（GPT）ではなく、「新しい技術を発明するための技術」であるGPMTと位置付けられています。
- **上流と下流の投資:** AIを有効活用するには、AIアルゴリズム自体の改善（上流）だけでなく、科学者のスキル習得や研究ワークフローの再編成（下流）という補完的な投資が必要です。

5. AIスキルと生産性（労働者拡張モデル）

- **AI専門家による増幅:** AI技術の向上は、そのツールを使いこなせる「AI専門家」である科学者の割合が高いほど、全体の生産性を非線形に向上させます。
- **タスクの開放と閉鎖:** AIが参入障壁を下げる（タスク・オープニング）場合もあれば、逆に高度な専門性をさらに必要とする（タスク・クロージング）場合もあり、これが賃金格差や研究の集中に影響を与えます。

6. AIの科学：スケーリングとアルゴリズム

- **スケーリング則:** 計算資源、データ、パラメータ数の増大が性能を向上させるという経験則について議論されています。性能と計算資源の関係は といったべき乗則に従う傾向があります。

+1

- **アルゴリズムの進化:** 単なるスケーリングだけでなく、推論能力の向上や「世界モデル」の学習といった、根本的なアルゴリズムの改善がAGI（汎用人工知能）へ

の鍵となります。

7. 科学における AI の潜在的なマイナス面

- **査読システムへの負荷:** AI による執筆支援で論文投稿が急増し、既存の査読システムが麻痺するリスクがあります。
- **知識の多様性の低下:** AI が既存データに基づいた「確実な」領域に研究を集中させることで、科学的な探究の幅が狭まる可能性が指摘されています。
- **知識の崩壊:** AI への過度な依存が人間の学習意欲を削ぎ、社会全体の知識ベースが失われる「知識崩壊」の懸念が論じられています。

8. 結論

- **拡張ツールとしての AI:** AI は人間の科学者を完全に代替するのではなく、その判断力を補完し、探索能力を拡張するツールとして捉えるべきです。
- **将来の展望:** AI を「知の自転車」として活用しつつ、人間が理解可能な形で科学を進展させ続けられるかどうか、今後の大きな課題となります。

この論文は、AI が科学の「やり方」そのものを変えることで、過去の技術革新を上回る経済的インパクトを与える可能性を論理的に解剖しています。

今回の要約の内容で、さらに詳しく知りたいセクションなどがありますか？

【3】Kawaguchi:AI 専門家とは

ご提示いただいた資料（特に Source 3 の論文）に基づくと、「AI 専門家 (AI-expert scientists)」とは、単に AI のコードが書ける人を指すのではなく、**特定の研究分野の深い知識（ドメイン知識）と、AI ツールを使いこなすスキルの両方を兼ね備えた科学者**を指します。

主な特徴と役割は以下の通りです。

1. AI 専門家の定義と構成要素

- **二つの専門性:** 自らの専門分野（生物学、物理学、経済学など）の知識と、AI を研究プロセスに組み込むための専門的なトレーニングの両方を持っています。
- **「普通」の科学者との違い:** AI に関する特別な訓練を受けていない「普通の (ordinary)」科学者と区別して定義されています。
- **判断力の補完:** AI ツールの限界（データの偏りや論理の飛躍など）を理解し、人間の「判断力」をもって AI の出力を評価・修正できる能力が含まれます。

2. 科学的生産性における役割

- **生産性の増幅器:** AI 技術が向上した際、その恩恵を最大限に引き出すのは AI 専門家であり、彼らの割合が科学界で増えるほど、全体の生産性向上は非線形に増幅さ

れます。

- **組み合わせ探索の効率化:** 科学のフロンティアにおける膨大な組み合わせ（新薬の候補や新材料のデザインなど）をナビゲートする際、AI を効果的に活用して探索を加速させます。
- **タスクの再定義:** 従来の人間による労働を AI に置き換える（自動化）だけでなく、AI を活用することで新しい研究手法を生み出す（拡張）役割を担います。

3. 労働市場と教育への影響

- **格差の要因:** AI 専門家は、新しい技術を使いこなすことで高い生産性を発揮し、普通の科学者に対して「賃金プレミアム（高い報酬）」を得る傾向があります。
- **補完的投資:** AI ツールの導入だけでなく、科学者に対して AI スキルの訓練を行う「下流への投資」が、科学全体の進歩を支える鍵となります。
- **スキルの空洞化リスク:** 一方で、AI を「補助輪」として使いすぎることで、科学者としての批判的思考や創造的な問題解決能力（AI 専門家の核となる能力）の育成が阻害されるリスクも指摘されています。

また、別の資料（Source 2）の観点から補足すると、LLM（大規模言語モデル）の内部的な確率分布（内部確信度）などを理解し、単なるテキスト出力以上の情報を引き出せる能力も、現代の AI 専門家が備えるべき高度なスキルの一例と言えます。

【4】Kawaguchi:探索の革命

「探索の革命」とは、AI が科学研究における膨大な選択肢（組み合わせ）の中から、正解や有望な候補を導き出すプロセスを根底から変えることを指します。

資料に基づき、この革命が具体的に何を意味するのか、その核心を整理します。

1. 組み合わせの爆発への挑戦

科学の最前線における最大の課題は、新しい「問い」「アイデア」「設計（デザイン）」「テスト」の組み合わせが天文学的な数にのぼる（組み合わせの爆発）ことです。

- **従来の限界:** 人間の認知能力では、これらすべての可能性を網羅的に探索（しらみつぶしに調査）することは物理的に不可能でした。
- **AI による突破:** AI は「予測マシン」として機能し、過去のデータやシミュレーションから、数億通りの選択肢を瞬時に評価して有望な領域を特定します。

2. デザイン生成の劇的加速

この革命が最も顕著に現れているのが、研究プロセスの第3段階である「デザイン生成」です。

- **タンパク質構造予測（AlphaFold）:** アミノ酸の並びからタンパク質の立体構造を

予測する問題は、その組み合わせの多さから従来は数年単位の時間がかかっていた。AIはこの探索時間を劇的に短縮し、科学の進歩を「数十年分圧縮」と言われます。

+1

- **新材料・新薬の発見:** 4,000 万件もの量子化学シミュレーションを学習した AI が、二酸化炭素を回収する新しい材料 (MOF) の設計図を提示するといった事例が生まれています。

3. 「予測」による探索コストの低下

AI の本質は、統計的なパターンに基づいて「次にくる最も可能性の高いもの」を予測することにあります。

+1

- **統計的模倣の力:** LLM (大規模言語モデル) は、膨大なテキストの字面から統計的必然性を見つけ出し、尤もらしい回答を生成します。これは意味を理解しているわけではありませんが、情報の海から「正解に近いパターン」を探し出す強力な手段となります。

+2

- **不確実性の定量化:** 最新の研究では、LLM が提示する予測の「内部確信度 (inner confidence)」を測定することで、どの探索結果がより信頼できるかを判断できるようになっています。

4. 人間の判断力との補完 (拡張)

AI が「探索」を担うことで、人間の役割は「作業」から「判断」へとシフトします。

- **実存的意図:** AI は統計的な「影」を提示しますが、その中からどの問いが真に価値があるか、どの設計が倫理的に許容されるかを決めるのは、人間にしかできない「実存的な意図」や「判断」です。

+1

- **GPMT (汎用メタ・テクノロジー):** AI はそれ自体が技術であるだけでなく、「新しい技術を探し出すための技術」として機能し、科学者の知性を拡張します。

この「探索の革命」により、科学的発見のスピードは指数関数的に向上する可能性を秘めていますが、同時に AI が提示する「統計的な正解」を人間がどう解釈し、責任を持って「意味」を付与していくかが、これからの科学者に求められる真の専門性となります。

+1

【5】科学者のスキル習得や研究ワークフローの再編成 (下流) と

いう補完的な投資

AI が科学に与える真のインパクトを引き出すためには、AI というテクノロジーそのものの進化（上流）だけでなく、それを受け入れる科学者側や組織側での「下流（downstream）への補完的投資」が不可欠です。

資料に基づき、この「下流」の投資が具体的にどのような内容を指すのかを整理します。

1. 科学者のスキル習得（AI 専門家への移行）

AI ツールを導入するだけでは不十分であり、それを使う人間側の専門教育が決定的な重要性を持ちます。

- **AI 専門家（AI-expert）の育成:** 「普通の科学者」がドメイン知識に加えて AI を使いこなすスキルを習得するためのトレーニングを指します。
- **生産性の増幅:** AI 専門家の割合が増えることで、AI 技術の向上による生産性向上の効果が非線形に増幅されるため、教育への投資は「拡張のレバー」として機能します。
- **高次スキルの保護:** 単なる作業の代替ではなく、AI と協力して複雑なトレードオフを評価したり、AI の出力を解釈したりするための「判断力」を養うことが求められます。

2. 研究ワークフローの再編成

従来の人間中心のプロセスに AI を「付け加える」のではなく、AI の特性に合わせて仕事の進め方そのものをデザインし直す必要があります。

- **AI とのチーム編成:** 人間と AI が連続的に相互作用しながら世界モデルを更新していく、新しい共同作業のプロトタイプを確立することです。
- **「工場の床」の再設計:** 歴史的に電力が工場のレイアウトを変えたように、AI を中心とした研究ワークフロー（アイデア生成、デザイン、テストの各段階の連携）の再構築が必要です。
- **自律型実験システムの導入:** AI が提示する膨大なデザイン候補を即座に検証できるよう、ハイスピードな自動ロボット実験システムなどと連携させる投資が含まれます。

3. なぜこれらの投資が「補完的」なのか

「補完的」とは、一方（AI）への投資だけでは成果が出ず、もう一方（スキルや組織）への投資があって初めて相乗効果が生まれることを意味します。

- **ボトルトップの解消:** AI が「デザイン生成」を 100 倍速くしても、人間がそれらの結果を「テスト」したり「解釈」したりするプロセスが旧態依然としたままであれば、全体の科学的生産性は向上しません。

- **ギザギザのフロンティアへの対応:** AI の能力は分野やステージによって不均一（ギザギザ）であるため、自らの分野における AI の限界を理解し、どこに人的資源を集中させるかを決定する組織的投資が必要です。
- **AlphaFold の事例:** タンパク質構造予測が加速した際、優れた研究所は人員を減らすのではなく、AI の予測を解釈・検証するための専門家（生物学者）を逆に増員して対応しています。

一言で言えば AI という「強力なエンジン」を積むなら、それに耐えうる「車体（ワークフロー）」と、それを操る「熟練のドライバー（AI 専門家）」を揃えるための投資こそが、科学の生産性を爆発させる鍵となります。

【6】Kawaguchi:上において、次の意味は？：科学プロセスを「質問生成」「アイデア生成」「デザイン生成」「テスト（検証）」の4つの主要なステージに分解しています

ご提示いただいた資料（Source 3）において、科学プロセスを4つのステージに分解することは、AI が科学の「知識生産関数（どのようにはかどるか）」に与える影響を論理的に解剖するためのフレームワーク（枠組み）を意味します。

単に「研究が速くなる」と考えるのではなく、どのプロセスで AI が働き、どこで人間が必要かを明確にするためのステップです。各ステージの意味は以下の通りです。

1. 質問生成（Question Generation）

研究の出発点となる「問い」を見つける段階です。

- **意味:** 膨大なデータからパターンを見つけ出す（ベーコン的帰納法）、あるいは既存の理論に反する「驚き」や「異常」を見つけ出すこと（パース的驚き）を指します。
- **AI の役割:** 人間には見えない微細なデータの相関を「見る」ための顕微鏡のような役割を果たします。
- **人間の役割:** その問いが社会的に重要か、研究する価値があるかという「規範的な判断」を下します。

2. アイデア生成（Idea Generation）

問いに対して、既存の知識を組み合わせる「仮説」や「理論」を立てる段階です。

- **意味:** 既存のアイデア（）の膨大な組み合わせの中から、もっともらしい説明を

「推測 (アブダクション)」することを指します。

- **AI の役割:** LLM (大規模言語モデル) などの「ブレインストーミング・ツール」として、新しい組み合わせを提示します。
- **人間の役割:** 提示されたアイデアが論理的に一貫しているか、真理に近いかを見極める「直感」や「判断力」を駆使します。

3. デザイン生成 (Design Generation)

立てた仮説を具体的に検証するための「設計図」を作る段階です。

- **意味:** 新薬の分子構造や、新材料の組成など、膨大な「組み合わせ探索空間」の中から具体的な候補を選定することを指します。
- **AI の役割:** このステージこそが AI の独壇場です。AlphaFold のように、人間には計算不可能な膨大な選択肢を瞬時に絞り込み、優先順位を付けます。

+1

4. テスト／検証 (Testing)

設計したデザインが実際に正しいか、物理的に確認する段階です。

- **意味:** 実験室での合成や臨床試験、あるいはシミュレーションの実行などを指します。
- **AI の役割:** ロボット技術と連携した自動実験や、実験データの高速解析を支援します。
- **人間の役割:** 実験結果が単なるエラー (ノイズ) ではないか、因果関係が正しく成立しているかという「最終的な検証」と「責任」を担います。

なぜこの分解が重要なのか？

論文の著者らは、全体の科学的生産性 () をこれら 4 つの掛け算 () としてモデル化しています。これには以下の意図があります。

- **「ギザギザのフロンティア」の特定:** AI が「デザイン生成 ()」を 100 万倍速くしても、物理的な「テスト ()」が遅ければ、全体の進歩は「テスト」の速さに引きずられてしまいます (ボトルネックの特定)。
- **人間と AI の棲み分け:** どのステージが「AI による自動化」に向いており、どのステージに「人間の判断力 (拡張)」を集中させるべきかを戦略的に判断するためです。
- **分野による違いの理解:** 例えば、データが豊富な生物学では「デザイン生成」が革新されますが、異常値が少ない物理学では「質問生成」の比重が依然として高い、といった分野ごとの個性を分析できます。