

(メンバーの皆さんへ：この論文はテクニカルですが、Agrawal et al (2026)の「AI 専門家 (AI-expert scientists)」の一例として位置づけてください)

はじめに

近年の人工知能、特に大規模言語モデル (LLM) の画期的な進展により、金融市場や学術研究での採用が飛躍的に加速しました。これらのモデルは人間の言語を模倣するのに非常に効果的であるため、最も自然な利用法は生成されたテキストのプロンプトと分析に関わるものとなります。直感的ではありますが、本論文では、テキスト出力だけに基づく意思決定は、特に重要性の高い状況ではしばしば最適ではないと論じます。生成されたテキストは、LLM の二つの異なる構成要素の結果です。ひとつは、過去のトークン列を与えられたときに次のトークンの確率分布を生成するニューラル言語モデルであり、もうひとつはこの条件付き分布から次のトークンを (確率的または決定的に) 選択するデコーディング戦略です。したがって、生成されたテキストにのみ注目することは、出力に伴う不確実性を無視し、モデル内部の信念に含まれる貴重な情報を破棄し、デコーディングプロセスによって追加の不透明性を導入することになります。

私たちの中心的前提は、LLM によって生成される条件付き確率、私たちが内部確率と呼ぶものが、経済的に意味のある情報を構成し、直接分析することによって意思決定を支援できるということです。これらの確率はデコーディング前のモデルの信念を要約しており、ほとんどのプライベートおよびオープンソースの LLM の標準的な出力です。これらの内部確率を直接扱うことによって、研究者はデコーディング戦略の特徴に抽象化でき、「ホワイトボックス」の予測不確実性の測定を得ることができます。

具体的には、我々は内的確率を用いて LLM の出力の不確実性を測定するエントロピーベースのフレームワークを提案する。このフレームワークは解釈可能であり、意味情報に敏感で、大規模な実証的応用に対しても拡張可能なように設計されている。このフレームワークはマルチトークンの不確実性測定に一般化可能であるが、多くの設定では LLM の応答を小さな既定の離散的回答セット (例:「はい」または「いいえ」;「ポジティブ」「ニュートラル」「ネガティブ」) に制限する方が望ましいと我々は主張する。このような制約は、類義語による不確実性の不適切な膨張 (確率質量が語彙的に異なるが意味的に同一のトークンに分散する場合) を排除し、マルチトークン生成に固有の不確実性フィードバックループを軽減し、透明で扱いやすい不確実性測定を可能にする。二項設定においては、エントロピー測定は単純な内部信頼統計量の単調変換である。

私たちは、提案する不確実性測度が、LLM の予測の客観的な不確実性を反映しているのか、それともモデルの主観的な信念に過ぎず、現実から完全に乖離している可能性があるのかを検証します。そのために、金融ニュース分類の実験を行います。市場時間中に発表

された 100,000 件の企業固有ニュースをサンプルとして、LLM (GPT-4o) に各ニュース項目が関連する企業の株価に対してポジティブかネガティブかを分類するように指示し、各予測の内部信頼度を計算します。同日の始値から終値までのリターンを真値として使用することで、内部信頼度と分類精度との間に強く単調な関係があることを確認しました。内部信頼度の上位 20% の予測では約 64.7% の精度が得られ、下位 20% の予測では約 51% の精度となります。上位群と下位群の精度の差は統計的に非常に有意です。

不確実性の指標の経済的意義を評価するために、内部信頼度をポートフォリオ構築に組み込みます。Lopez-Lira と Tang (2023) に従い、LLM に対して、翌日の短期的株価パフォーマンスに対する前夜のニュースの影響（プラスまたはマイナス）を評価させ、それぞれの予測に対応する内部信頼度を計算します。ローリングウィンドウ手法を用いて、すべての LLM 予測を高信頼度グループと低信頼度グループに分類する内部信頼度の閾値を推定します。その後、各グループ内でロング・ショートポートフォリオを構築し、翌日の寄り付きから引けまでのリターンを計算し、これらのポートフォリオのパフォーマンスを、全サンプルを使用して形成したベースラインのロング・ショートポートフォリオと比較します。

Lopez-Lira と Tang (2023) に従うと、全サンプルから構築されたベースライン戦略は、年率換算の平均超過リターンが 40%、シャープレシオが 4.24 となります。高内的信頼ポートフォリオでは、平均超過リターンは 50% に上昇し、シャープレシオは 5.15 に上昇します。一方、低内的信頼ポートフォリオは平均超過リターンが -10%、シャープレシオが -0.39 となり、いずれも統計的にはゼロと区別できません。これらの結果は、内的信頼が、LLM の予測が経済的に信頼できない場合を効果的に特定し、投資判断の基礎として使用すべきでないことを示しています。

私たちは、これらの知見が高信頼度と低信頼度の閾値を設定する代替的な方法に対しても頑健であることを示します。さらなる分析により、高内的信頼度のロング・ショートポートフォリオにおけるシャープレシオは、時価総額が低く、流動性が低く、メディアやアナリストのカバレッジが少ない株式で特に高いことが示され、超過リターンは主にショート側から生じていることがわかります。これらの横断的パターンは、ロング・ショート戦略のパフォーマンスが、特に小型で流動性が低く、メディアやアナリストによるカバレッジが少ない株式におけるニュースへの市場の過小反応を特定する LLM の能力によって駆動されているという解釈と一致します。全体として、これらの知見は、特に不確実性の定量化のために内的確率を組み込むことが、LLM 予測に基づく戦略のパフォーマンスを大幅に向上させる可能性があることを示しています。

上記の二つの実験は、エントロピーに基づく不確実性の測定が有益であることを示しているものの、LLM の信念が偏りのないものであるとか、経済結果における真の不確実性のレベルを正確に反映していることを意味するわけではありません。実際、最近の研究では、現代の LLM が人間の期待で観察される偏りと類似した偏りを示すこと (Bybee, 2023;

Fedyk, Kakhbod, Li, および Malmendier, 2024)、しばしば誤った校正を行っていること、および過度に集中した確率を生成する傾向があることが示されています（例えば、Desai and Durrett, 2020; Jiang, Kim, Guan, and Gupta, 2021）。それにもかかわらず、内的確率やそれに関連する不確実性の測定における小さな差でも依然として有意な情報を持つことがあります。これが、我々の応用において絶対的なレベルではなく、内的信頼度の相対的な順位に注目する理由です。

内的自信と予測精度との経験的な関係を超えて、私たちは LLM の内的自信を駆動する要因を調べ、その信念形成プロセスをよりよく理解しようとしています。まず、企業レベルおよび市場レベルのどの変数が、LLM のニュース分類に対する自信と体系的に関連しているかを調べます。我々は、内的自信は、次の 30 日間の企業レベルのリターンが弱いニュースや、企業レベルのリターンの変動率が高いニュースの場合に低い（すなわち不確実性が高い）ことを見出しました。異常に高い取引量を伴うニュースでも自信は低く、これは投資家間の意見の不一致が大きいことと一致しています。市場レベルでは、異常に高い総ニュース量がある日に発表されたニュースは、より低い内的自信と関連しています。

次に、ニュースのテーマと内的自信の関係を検討します。我々は、Bybee, Kelly, Manela, Xiu (2024) で公開された単語の重みを用いて、サンプル内の各ニュース項目を 180 の事前定義されたトピックカテゴリーのいずれかに割り当てます。その後、トピック指標を用いて各記事の内的自信のデシルを予測するラッソ回帰を推定します。チューニングパラメータは、モデルが最も情報量の多い 10 カテゴリーを選択するように選びます。全サンプルの結果は、LLM が訴訟、オプション取引、または製品開発に関連するニュースを処理する際により高い内的自信を示し、記者会見や調査に関する項目については自信が低いことを示しています。この手順を個々の企業に適用すると、ニューステーマに応じた情報の複雑さにおける企業レベルの異質性が明らかになります。

第三に、私たちはプロンプティングを使用して LLM の事前信念と知覚される信号精度を操作し、内部信頼度に対する結果を調べます。ニュース分類の設定において、LLM は事前学習中に形成された企業に関する事前信念を持っていると見なすことができます。ニュース記事が信号として機能し、それに基づいて事後を生成します。このプロセスをベイズフレームワークと比較することは、モデルの経済的合理性を評価する有用な方法を提供します。

具体的には、私たちは最初のニュース分類実験を、3 種類の修正版プロンプトの下でやり直します。まず、アナリストが企業の一般的な見通しについて同意（または不同意）していることを示します。この変更は、モデルの将来のリターンに関する事前の不確実性を変えることを目的としています。次に、アナリストが特定のニュース項目の解釈について同意（または不同意）していることを示し、それによってモデルの認識する信号の精度を変更します。最後に、プラセボとして、事前や信号を明示的に変更せずに、高いまたは低い人間の自信に一般的に関連する言葉を付加する 3 つ目のプロンプトを導入します。ベ

ズ学習者と一貫して（少なくとも方向性として）最初の2つのプロンプト条件付けは、モデル内部の信頼度を期待される方向に変化させます。アナリストが企業の見通しに同意している場合やニュース信号が正確であると認識される場合、モデルの分類に対する信頼度は高まります。対照的に、ランダムに追加された信頼度に関連する言葉は効果を持ちません。

経済的な関連性と内的自信の決定要因を明らかにした上で、次にそれがLLM（大規模言語モデル）における金融分野の重要な議論にどのように影響するかを検討します。それは、予測モデルの出力が意図せず事前学習データに含まれる将来の情報を反映してしまう、いわゆる先見バイアスの存在です。考え方として、もしLLMが記憶した結果を思い出すことで予測を行う場合、高い予測精度は人工的に高い内的自信を伴っている可能性があります。この考えを検証するために、Didisheim、Fraschini、Somoza（2025）、およびLopez-Lira、Tang、Zhu（2025）に従い、LLMに追加の文脈なしで個別資産の実現リターンを思い出させるよう促します。この設計により、追加文脈による混乱効果から潜在的な記憶効果を分離できます。この設定において、モデルの内的自信と実際のリターンを正しく思い出す能力の間に強い正の相関があることを明らかにしました。

証拠は、異常に高い内的自信が暗黙の記憶の想起の診断信号として機能し得ることを示唆しており、これによりLLMベースの金融アプリケーションにおける先読みバイアスを検出する実用的な手段が提供される可能性があります。我々はこの考えをニュース分類の設定に適用し、GPT-4oのトレーニングカットオフ日の前後1年間のサンプル内の全金融ニュースにおける日次の平均内的自信の時系列を比較します。もし予測パフォーマンスを先読みバイアスが駆動している場合、暗記された結果が潜在的に想起され得るカットオフ前の期間において、体系的に高い内的自信が見られることが予想されます。しかし、我々は両期間間で内的自信に統計的に有意な差がないことを見出しました。むしろ、内的自信はカットオフ後のサンプルでわずかに高い傾向があります。このパターンは、金融ニュース分析におけるLLMの先読みバイアスはモデルの混乱によって生じる効果よりも小さいと報告しているGlassermanとLin（2023）の結果と一致しています。

最後に、本論文でのホワイトボックス不確実性測定と、内部の確率に依存せずモデルの不確実性を推定するブラックボックス手法を比較します。そのような手法の1つは、同じプロンプトを用いた繰り返しクエリにおけるモデル出力の分散を調べることで不確実性を測定します。この方法は計算コストが高いだけでなく、ノイズが多く、ハイパーパラメータの選択（温度）に敏感です。直感的に魅力的な別のブラックボックス測定は宣言的信頼度であり、主要な出力に対する自身の信頼度を直接LLMに報告させることで得られます（例：Bybee, 2023; Fedyk et al., 2024 参照）。

私たちは、ポートフォリオ実験において宣言された自信と内的自信の情報量を比較します。これら二つの指標の順位相関は0.74（ピアソン相関は0.38）です。内的自信とは異なり、宣言された自信を条件としても戦略のパフォーマンスは向上しません。高宣言自信の

ロング・ショート・ポートフォリオの平均超過リターンはベースライン・ポートフォリオよりも高くなく、シャープレシオは有意に低いです。

さらに、宣言された確信度はデコーディングプロセスによって体系的にバイアスされることを示します。それは、予測トークンに続いて生成されるトークンであるため、その条件付き分布は主要な出力の実現されたデコーディング結果に依存します。再びこのバイアスを示すためにニュース分類の設定を使用します。プロンプトは LLM にニュース項目を (A) ポジティブまたは (B) ネガティブとして分類し、その後 0 から 1 の間で確信度スコアを報告するよう求めます。同じニュース項目に対してこのプロンプトを複数回実行し、分類にランダム性を導入します。LLM の信念の不確実性はニュース項目のみに依存し、選択された予測トークンに依存しないはずですが、同じニュース項目であっても、予測トークンが "A" の場合には "B" の場合よりも宣言された確信度が平均で 0.0337 高くなることがわかります。

論文要約：ブラックボックスを脱して：条件付き確率による LLM の不確実性の定量化 (Out of the Black Box: Uncertainty Quantification for LLMs via Conditional Probabilities)

Hui Chen、Antoine Didisheim、Luciano A. Somoza によるこのワーキングペーパーは、大規模言語モデル (LLM) の内部確率分布を利用して、経済・金融の文脈における予測の不確実性を測定する方法を検証しています。

核となる前提：内部確率 (Inner Probabilities)

著者らは、LLM のテキスト出力のみに基づいて意思決定を行うのは、モデルの「内部的な信念」を無視しているため不十分であると主張しています。彼らは LLM を以下の 2 つの要素に分けて考えています。

- ニューラル言語モデル: 先行する文脈に基づいて次のトークンに対する条件付き確率分布を生成します。これを「内部確率 (Inner Probabilities)」と呼びます。
- デコーディング・戦略 (Decoding Strategy): その分布から (確率的または決定論的に) 実際のテキスト出力を選択する別のプロセスです。

内部確率を直接分析することで、特定の (しばしば不透明な) デコーディング・戦略に依存しない、不確実性の「ホワイトボックス」的な測定が可能になります。

提案された指標：内部確信度 (Inner Confidence)

本論文では、不確実性を定量化するためのエントロピーベースのフレームワークを提案しています。ニュースが「ポジティブ (A)」か「ネガティブ (B)」かといった二元的な設定において、最大の不確実性 () からの距離に基づいて内部確信度を定義します。

+1

著者らは、LLM の回答を離散的なラベル (「A」や「B」など) に限定することを推奨しています。これは、初期のトークンのランダム性が後のテキストの予測不能性を増幅させる

「不確実性のフィードバックループ」を緩和するためです。

+1

主な実証的知見

10 万件の金融ニュースと GPT-4o を用いた実験の結果、以下のことが明らかになりました。

- **確信度と精度の関係:** 内部確信度が高い予測は、体系的に精度が高いことが示されました。確信度の上位 20% の予測は **64.7% の精度** を記録したのに対し、下位 20% は **約 51%** (ランダムな推測に近い) に留まりました。

+1

- **ポートフォリオのパフォーマンス:** 高い内部確信度に基づく LLM の予測を利用した投資戦略は、**5.15 というシャープレシオ** を達成しました (全ニュースを含むベースラインより約 20% 高い)。一方で、低確信度の予測に基づくポートフォリオは、統計的に有意な超過収益を生み出しませんでした。

+1

- **確信度の決定要因:** 内部確信度は、その後の株価ボラティリティが高いニュースや、異常な取引高を伴うニュースにおいて低くなる傾向がありました。これは、LLM の内部的な不確実性が、実際の市場の意見の不一致や複雑さを反映していることを示唆しています。

+1

- **トピックによる異質性:** LLM は、訴訟や製品価格など方向性が明確なトピックに対して高い確信度を示し、研究や記者会見などのニュアンスが複雑な領域では確信度が低くなる傾向がありました。

「自己申告された確信度 (Declared Confidence)」との比較

本研究では、「内部確信度」と、モデルに自身の確信度を尋ねる「自己申告された確信度」を対比させています。

- **バイアス:** 自己申告された確信度は **デコーディング・バイアス** の影響を受けます。同じニュース項目でも、最初にどの予測トークンがサンプリングされたかによって、モデルが報告する確信度が変動してしまいます。
- **有用性:** 内部確信度とは対照的に、自己申告された確信度を条件とした投資戦略では、有意なパフォーマンスの向上は見られませんでした。

先読みバイアス (Look-Ahead Bias) の診断

著者らは、異常に高い内部確信度が、**先読みバイアス** (モデルが予測ではなく、学習データから将来のデータを「想起」している状態) の診断ツールになり得ることを発見しました。モデルが記憶された結果を想起して正解した場合、通常、人工的に高い内部確信度が表示されます。しかし、学習データのカットオフ日を跨いだ検証の結果、GPT-4o による日次のニュース分析において、先読みバイアスが主要なパフォーマンス向上要因であると

いう強い証拠は見つかりませんでした。

+2